

ALAN VERAS

AI Developer | LLM, RAG & Agentic Systems in Production | Python · LangGraph · AWS · Docker
alanvictorriou@gmail.com | github.com/alan-veras | linkedin.com/in/alan-verass

RESUMO PROFISSIONAL

Construo e opero **sistemas de LLM em produção**, e sou o **AI engineer** que também responde pela **infraestrutura** por baixo deles. Na **Youlex** (legaltech), entreguei **60+ melhorias em produção em 6 meses**, com **observabilidade de custo de LLM**, redução de latência, **resiliência de provedores de LLM** e **hardening de IAM**, e opereei o **pipeline de dados/ML de 8 estágios** com **quality gates automáticos**. Como consultor independente, provisionei e opereei infraestrutura em **VPS** (DigitalOcean, Contabo, Hetzner) rodando **agentes de IA containerizados 24/7**. Do lado de IA, coordeno **agentes jurídicos em LangGraph** e já desenhei **77+ tarefas de avaliação de LLMs agênticos**, entre avaliação adversarial de prompts e agentes com uso de ferramentas.

COMPETÊNCIAS TÉCNICAS

Infraestrutura, Cloud & DevOps: Linux (administração e provisionamento em VPS: DigitalOcean, Contabo, Hetzner), AWS (EC2, ECR, ECS, S3, CloudWatch, IAM, VPC/Security Groups), Docker, CI/CD (GitHub Actions), Cloudflare (edge, R2), Nginx/proxy reverso, Redes e DNS, Gestão de Secrets, Shell Script/Bash

Observabilidade & Confiabilidade: Amazon CloudWatch (métricas, logs e alarmes), Grafana, quality gates automáticos, monitoramento de latência (p95), métricas de SLA e taxa de resolução

Automação & Plataforma de Dados: Orquestração de pipelines (LangGraph, ARQ/Redis), n8n, versionamento de artefatos, PostgreSQL, Supabase, Redis, REST APIs, WebSockets

IA & Sistemas RAG: RAG Híbrido (BM25 + denso + fusão RRF), Rerankers (BGE), Legal-BERTimbau, PyTorch, Transformers (HuggingFace), BERTopic, Integração com LLMs (Gemini, GPT-4, Claude, DeepSeek), Avaliação de LLMs (77+ tarefas agênticas), Model Serving (FastAPI, streaming SSE)

Linguagens & Frameworks: Python, FastAPI, Bash, TypeScript, Node.js (Nest.js, Express.js, Fastify), Go, React, Next.js

Segurança Aplicada: Detecção e sanitização de PII, guardrails e safety gates, RBAC/ABAC, audit logging e rastreabilidade, hardening de autenticação, teste de prompt injection

Práticas: pytest, Jest, Vitest, TDD, Agile/Scrum, Liderança Técnica, Workflows Multi-Agente (8+ agentes em ciclos de mesa redonda para code review)

EXPERIÊNCIA PROFISSIONAL

Youlex

Março 2026 - Agosto 2026

Founding Engineer: Infraestrutura & IA / Legaltech

- Orquestrei **equipes de agentes de IA multi-provider** (Claude, GLM e outros) com **revisão humana e gates de qualidade** por etapa, entregando **60+ melhorias em produção em 6 meses**
- Construí e opereei o **pipeline de dados/ML de 8 estágios** que processa **7,2 GB** de dados abertos do TCU (**199 mil acórdãos**, 17.883 docs curados): ingestão, **sanitização zero-PII**, topic modeling (**BERTopic**) e embeddings, com **quality gates automáticos** por estágio e artefatos versionados publicados apenas após o gate de **Recall@5 ≥ 90%**
- Implantei **observabilidade de custo de LLM ponta a ponta**: tabela de chamadas particionada por dia no **Postgres**, flush em batch via worker **Redis (ARQ)**, endpoint de **custo por peça com percentis**, conversão **USD → BRL** via API do BCB e **reconciliação automática com a fatura GCP** do provedor de LLM em dashboard **Grafana**
- Conduzi a **barateização da infraestrutura** redimensionando os tamanhos de **instância EC2** com base em métricas reais do **CloudWatch** (RAM de pico medida antes de cada provisionamento)
- Conduzi a **migração da cadeia de agentes em LangGraph** (revisor, auditor, pesquisador) de **APIs individuais de provedores** para **OpenRouter**, reduzindo **custo** e elevando a **qualidade** das respostas com seleção de modelo por tier de persona

- Construí a **camada de resiliência de LLM** sobre OpenRouter: abstração de provider com **circuit breaker**, **retry** e **context cache**; **fallback em cascata** validado por **teste A/B** antes do go-live; **prompt caching** nativo (Anthropic ephemeral + DeepSeek)
- Formalizei ambiente de **homologação (UAT)** com **cópia anonimizada da produção** e **CI/CD de migrations** no **GitHub Actions**; **diagnostiquei e corriji em produção** um deploy que embutia localhost:8000 e derrubou o frontend; executei **hardening de IAM na AWS** (policy **least-privilege** para o plano de controle do **ECS** validada com **simulate-principal-policy**; retenção de 30 dias nos logs de 5 containers)

Self-employed

Agosto 2025 - Abril 2026 (transição para a Youlex)

Consultor Independente: Infraestrutura & Engenharia de IA

- Provisionei e operei **infraestrutura 24/7 em VPS Linux de múltiplos provedores** (DigitalOcean, Contabo, Hetzner), dimensionando instâncias e administrando **Docker**, **n8n**, Postgres/Supabase e **Redis** para produtos de IA, com integração de **APIs de WhatsApp** (Uazapi/Evolution) a **Gemini + OpenAI** e instrumentação de métricas de **SLA, resolução e funil**
- Entreguei, ponta a ponta, **agentes de WhatsApp** para empresa local (operação ago-dez): resposta de **6 a 12h para 1 a 3min, 24/7**, com triagem, qualificação e follow-up automatizados de **10 a 15 conversas/dia** e **handoff humano** para casos sensíveis
- Reduzi o tempo de entrega de features em **3x (2 a 3 dias vs. 1 a 2 semanas)** com um **fluxo de CI/CD multi-agente de 8+ agentes de IA** (auditor de código, gerador de testes, revisor de impacto)

Projeto Ares

Novembro 2024 - Atualmente

Diretoria Geral de Extensão e Pesquisa: Projeto Ares (UFC)

- Progridi de membro (estudos em **computação forense**) a **pesquisador blue team** e, hoje, à **Diretoria Geral de Extensão e Pesquisa**, liderando time de **~14 pessoas em 3 squads** (Comunicação, Desenvolvimento, Pesquisa) em uma trajetória que atravessou a pausa institucional de 2025 e o relançamento do projeto em 2026
- No período, o projeto entregou: **aceitação em processo seletivo do Instituto Atlântico** (2024), **artigo publicado** (2025), **minicursos** em 2025 e na UFC (2026) e **palestras** em parceria com perita de computação forense e profissional de blue team
- Implantei **cadência semanal de rituais** (weekly, planning, retrospectivas) e backlog em **Kanban**, sustentando a entrega contínua de projetos, documentação e eventos de extensão
- Co-construí **materiais e documentação de capacitação** para a rampa técnica e o onboarding de novos membros, e organizei **1 CTF presencial** de segurança com **~15 a 20 participantes**

Outlier

Junho 2026 - Atualmente

Avaliação de LLMs: Tarefas Agênticas (Freelance)

- Desenhei **77+ tarefas de avaliação** para LLMs agênticos, entre **avaliação adversarial de prompts** e prompt security (60+) e comportamento de agentes com uso de ferramentas (17+), e elaborei **rubricas ponderadas** em Task Completion, Instruction Following, Factualidade, Tool Use e Safety, com critérios atômicos ancorados no prompt
- Rodo o modelo na plataforma e **pontuo as trajetórias manualmente** contra a rubrica, com justificativas ancoradas em evidência, identificando **modos de falha genuínos** e descartando alavancas que não discriminam

FORMAÇÃO, CERTIFICAÇÕES & IDIOMAS

Ciência da Computação (ênfase em Inteligência Artificial) | Universidade Federal do Ceará | 2023 - 2027 |

Idiomas: Inglês (Profissional), Português (Nativo)

Certificações: AWS Cloud Practitioner e CKA (em preparação) | SQL para Ciência de Dados | EF SET English B2